Продвинутая линейная алгебра



Типы матриц. Собственные вектора и собственные значения. Матричные разложения. Приближение матрицей меньшего ранга. Сингулярное разложение и низкоранговое приближение.

Даниил Корбут

Специалист по Анализу Данных





Даниил КорбутDL Researcher
Insilico Medicine, Inc

Окончил бакалавриат ФИВТ МФТИ (Анализ данных) в 2018г Учусь на 2-м курсе магистратуры ФИВТ МФТИ Работал в Statsbot и Яндекс. Алиса.

Сейчас в Insilico Medicine, Inc, занимаюсь генерацией активных молекул и исследованиями старения с помощью DL.



Типы матриц

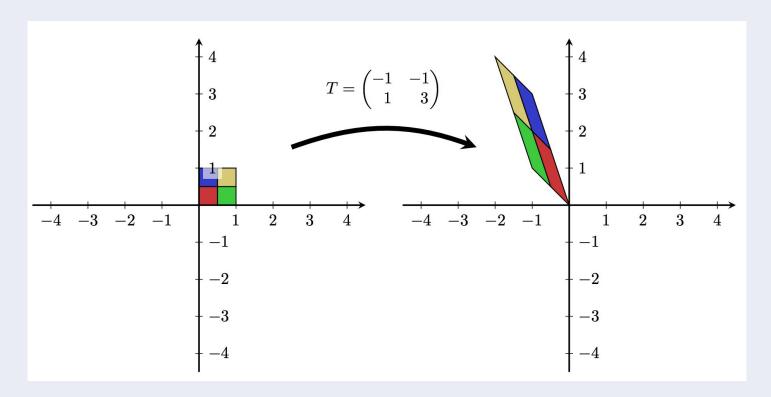
$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ & \cdot & \cdot & \cdot \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

- 1. m=n => квадратная, иначе прямоугольная
- 2. m = 1 => матрица-строка
- 3. n=1 => матрица-столбец
- 4. нулевая матрица, если все элементы = 0
- 5. диагональная (единичная)
- 6. треугольная(нижнетреугольная, верхнетреугольная)
- 7. ортогональная

$$AA^T = A^TA = E$$

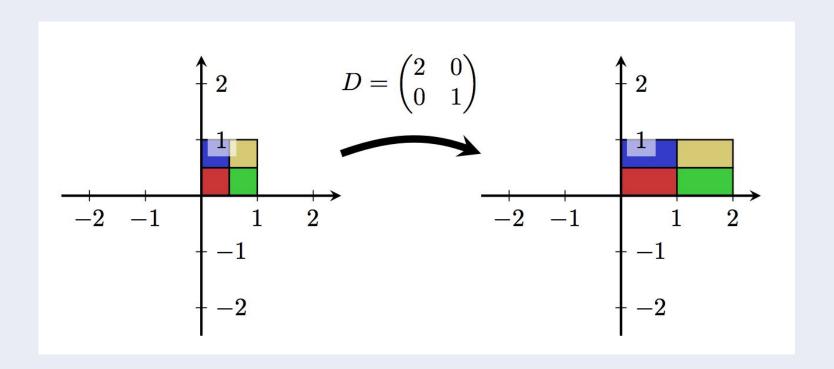


Типы матриц (преобразование пространства)



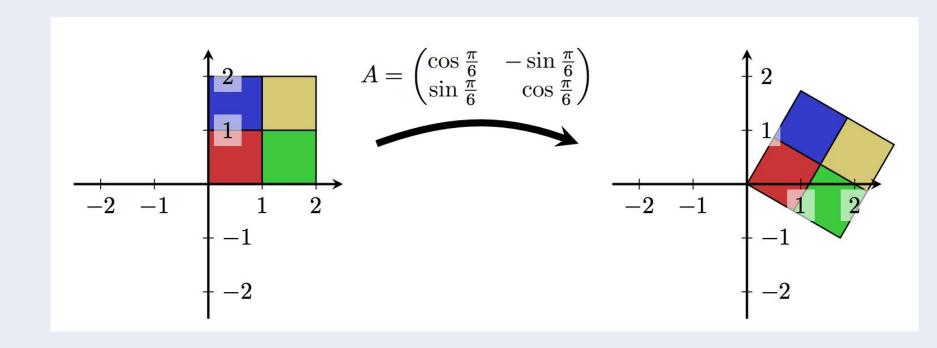


Типы матриц (преобразование пространства)



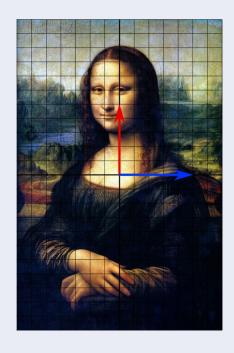


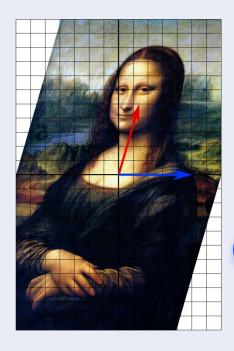
Типы матриц (преобразование пространства)





Собственные векторы и собственные значения





Собственный вектор преобразования А

$$AX = \lambda X$$

X - собственный вектор (ненулевой!) lambda - собственное значение

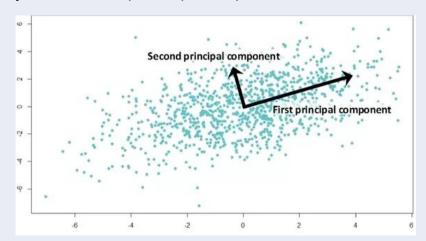
У матрицы **n x n** не более **n** собственных значений

https://ru.wikipedia.org



Собственные векторы и собственные значения: применение

- 1. Собственные векторы направления, в которых матрица лишь растягивает или сжимает векторы, но не поворачивает
- 2. Показывают направления наибольшего изменения
- 3. Возникают при уменьшении размера матрицы





Собственные вектора и собственные значения (поиск)

$$A - \lambda E$$

характеристическая матрица матрицы А

$$|A - \lambda E|$$

характеристический многочлен матрицы А

$$|A - \lambda E| = 0$$

характеристическое уравнение матрицы А



Теорема. Собственными числами матрицы A являются корни характеристического уравнения матрицы A и только они.



Собственные вектора и собственные значения (пример)

$$A = \begin{pmatrix} -1 & -6 \\ 2 & 6 \end{pmatrix} \longrightarrow \begin{vmatrix} -1 - \lambda & -6 \\ 2 & 6 - \lambda \end{vmatrix} = 0$$

$$\lambda^2 - 5\lambda + 6 = 0$$

$$\lambda_1 = \frac{5-1}{2} = 2$$

$$\lambda_2 = \frac{5+1}{2} = 3$$

$$\begin{cases} -4x - 6y = 0 \\ 2x + 3y = 0 \end{cases} \quad x = -\frac{3}{2}y$$

$$\begin{cases} -3x - 6y = 0 \\ 2x + 4y = 0 \end{cases} \Rightarrow x = -2y$$

$$\begin{cases} -4x - 6y = 0 \\ 2x + 3y = 0 \end{cases}$$

$$x = -\frac{3}{2}y$$

$$\begin{cases} -3x - 6y = 0 \\ 2x + 4y = 0 \end{cases} \Rightarrow x = -2y$$

Ответ: собственные числа: $\lambda_1 = 2$, $\lambda_2 = 3$, собственные векторы: $\overline{u}_1 = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$, $\overline{u}_2 = \begin{pmatrix} 3 \\ -2 \end{pmatrix}$



Матричные разложения (спектральное разложение)

Разложение матрицы - представление в виде произведения некоторых других, обладающих интересными свойствами.

Пример: спектральное разложение Х

$$X = S^T \cdot D \cdot S$$

X - симметричная, S - ортогональная, D - диагональная из собственных значений X.

Часто встречаются квадратичные формы

$$f(y) = y^T X y$$

с помощью спектрального разложения приводим к более простому виду:

$$f(y) = y^T \cdot S^T \cdot D \cdot S \cdot y = (S \cdot y)^T \cdot D \cdot (S \cdot y) = z^T \cdot D \cdot z = \sum_{i=1}^n \lambda_i z_i^2,$$



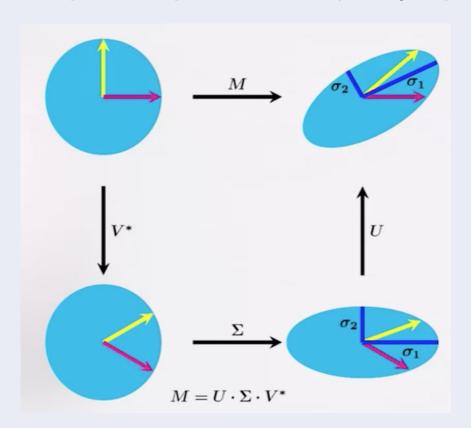
Матричные разложения (сингулярное разложение)

Но это была симметричная матрица, что в случае произвольной?





Матричные разложения (сингулярное разложение)



Сингулярное разложение представляет линейное преобразование в виде композиции: вращения, растяжения по осям, вращения.



Что такое ранг матрицы?



- Матрица задаёт отображение, ранг в какой-то степени мера "сложности" отображения
- Ранг максимальное количество линейно независимых столбцов или строк
- Ранг максимальный размер подматрицы с ненулевым определителем
- ! rank(X) <= min(n, m), если X матрица m x n

Пусть X = AB, A размера (m, k), B размера (k, n) Пусть также k < m, k < n Что можно сказать о ранге X?



- Матрица задаёт отображение, ранг в какой-то степени мера "сложности" отображения
- Ранг максимальное количество линейно независимых столбцов или строк
- Ранг максимальный размер подматрицы с ненулевым определителем
- ! rank(X) <= min(n, m), если X матрица m x n

Пусть X = AB, A размера (m, k), B размера (k, n) Пусть также k < m, k < n**Что можно сказать о ранге X?**

Bерно! $rank(X) \le k$



Зачем приближать матрицу матрицей меньшего ранга?

Мы предполагаем, что матрица преобразования X на самом деле более простая.

Что значит приблизить

$$X \approx X' = UV^T$$

$$U-m\times k, V-n\times k$$

Просто найлучшее приближение по норме: $||X-UV^T|| o min$



Что значит приблизить

$$X pprox X' = UV^T$$

$$U-m\times k, V-n\times k$$

Просто найлучшее приближение по норме: $||X-UV^T|| o min$

$$||X||_F = \sqrt{\sum\limits_{i,j} x_{ij}^2}$$

Итоговая задача выглядит так:

$$U, V = \operatorname*{argmin}_{U \in \mathbb{R}^{m \times k}, V \in \mathbb{R}^{n \times k}} \sum_{i,j} \left(x_{ij} - u_i^T v_j\right)^2$$



Матричные разложения (пример применения)

- **)** Пусть X матрица признаков объектов
- $oldsymbol{U}$ матрица новых признаков
-) При k < n преобразование признаков понижает размерность пространства
-) По U с максимальной возможной точностью восстанавливаются исходные признаки X



Матричные разложения (пример применения)

- **)** Пусть X матрица с оценками x_{ij} , поставленными пользователем i фильму j
-) Некоторые значения матрицы неизвестны
-) $x_{ij} \approx \widehat{x_{ij}} = u_i v_j$, где u_i отражает интересы пользователя, а v_j признаковое описание фильма
-) Идея: настроим u_i и v_j на известных x_{ij} , а неизвестные спрогнозируем
- Будем рекомендовать фильмы, для которых спрогнозирована высокая оценка

Что делать с пропущенными значениями?



Матричные разложения (пример применения)

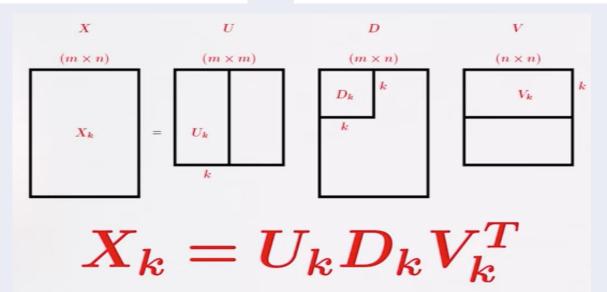
-) Пусть X матрица с оценками x_{ij} , поставленными пользователем i фильму j
-) Некоторые значения матрицы неизвестны
-) $x_{ij} \approx \widehat{x_{ij}} = u_i v_j$, где u_i отражает интересы пользователя, а v_j признаковое описание фильма
-) Идея: настроим u_i и v_j на известных x_{ij} , а неизвестные спрогнозируем
- Будем рекомендовать фильмы, для которых спрогнозирована высокая оценка

$$U, V = \operatorname*{argmin}_{U \in \mathbb{R}^{m \times k}, V \in \mathbb{R}^{n \times k}} \sum_{i, j: x_{ij} \neq 0} \left(x_{ij} - u_i^T v_j \right)^2$$



Матричные разложения (связь SVD и низкорангового приближения)

$$\hat{X} = \operatorname*{argmin}_{\operatorname{rg} \hat{X} \leq k} \|X - \hat{X}\|$$
 $X = U \cdot D \cdot V^T$



Усечённый SVD



Матричные разложения (связь SVD и низкорангового приближения)

Оказывается, Xk - наилучшее приближение матрицы X матрицей ранга <= k по норме Фробениуса!

$$egin{aligned} X_k &= U_k D_k V_k^T \ \hat{X}_k &= rgmin_{i,j} ||X - \hat{X}||_F \ rg(\hat{X}) \leq k \end{aligned}$$



Матричные разложения (рекомендательные системы)

-) Вариант 1 (не очень правильно, но просто): сделать SVD, матрицу $U_k D_k$ использовать как матрицу профилей пользователей, а матрицу V_k как матрицу профилей фильмов, произведение профилей прогноз оценки фильма
-) Вариант 2 (более правильно, но нужно более глубоко вникнуть в метод): Не будем никак использовать SVD, а просто подберем U и V, минимизируя функционал



Спасибо за внимание!

